

Estudio sobre los Cristales

Mario Álvarez Martínez, Jorge Aranda Honrubia, Pablo de Puelles Carceles,
Julia Ruiz Picó, Cristina Tárraga Herrero (Grupo A1-10)

2026-04-14

Exploración y preparación de la BBDD

Descripción y naturaleza de las variables

	variable	tipo
RI	RI	numerical
Na	Na	numerical
Mg	Mg	numerical
Al	Al	numerical
Si	Si	numerical
K	K	numerical
Ca	Ca	numerical
Ba	Ba	numerical
Fe	Fe	numerical
type	type	categorical
hardness	hardness	numerical
color	color	categorical
transparency	transparency	categorical
density	density	numerical
thermal_exp	thermal_exp	numerical

Nos encontramos ante una base de datos que registra información sobre distintos cristales. La base original procede del conjunto de datos Glass del paquete mlbench de R.

Inicialmente, se han registrado 15 variables para 182 muestras de cristales.

La base de datos recoge 8 variables referidas a la composición química de las muestras, representadas como las proporciones relativas de los distintos elementos químicos presentes en el cristal.

También se incluyen parámetros físicos, tales como el índice de refracción (RI), la densidad y la dureza del cristal, medida esta última en una escala ordinal tipo Mohs, donde 1 indica menor dureza y 7 mayor dureza.

Además, presenta 3 variables categóricas, la primera de ellas recodificada como valores 1-4:

- type: tipo de cristal según su uso (1: ventanas de edificios con vidrio flotado; 2: ventanas de edificios sin vidrio flotado; 3: ventanas de vehículos con vidrio flotado; 4: envases y artículos de mesa; 5: faros).
- color: indica el color del cristal (CL: transparente; WH: blanco; OT: otros colores).
- transparency: indica el nivel de transparencia del cristal (TP: transparente; TL: translúcido; OP: opaco).

Por último, detectamos la variable thermal_exp. Como no se conoce su significado concreto, se decide su eliminación, actualizando por tanto la tabla de clasificación de las variables.

Análisis descriptivo

Variables constantes o casi constantes

Queremos comprobar si existe alguna variable con variabilidad reducida o inexistente.


Para las variables numéricas se opta por utilizar el coeficiente de variación, mientras que para las variables categóricas se obtendrán dos tablas de frecuencias (absolutas y relativas) y se comprobará si una sola categoría contiene la mayoría o totalidad de los datos.

Por ahora se decide no eliminar ninguna variable, ya que ninguna de ellas presenta un comportamiento constante o casi constante. Se considera que todas pueden aportar información valiosa al análisis.

Valores inconsistentes o anómalos

A continuación se analiza si alguna de las variables presenta valores que no son posibles dentro del rango de definición de la variable.

Por un lado, el estudio de los valores anómalos de las variables numéricas parte de la representación de cada una de ellas en un diagrama de caja y bigotes, aplicando la función `scale` para analizar los valores en términos relativos.



Destacan valores extremos en las variables K y Ba.

La proporción relativa de potasio en los cristales se mueve entre valores de 0 y 3, por lo que interpretamos los dos valores extremos 6.21 como errores y los reemplazamos por valores faltantes (NA).

El bario es un elemento presente en los cristales en proporción muy dispar, según la asimetría de la distribución. Mantenemos los valores anómalos, como reflejo del comportamiento real de la variable.

No identificamos ningún valor inconsistente en los datos de color y transparencia de los cristales, a partir de los gráficos de barras.

Valores faltantes

Los únicos valores faltantes presentes en la base de datos son los dos NA forzados en la variable K por la presencia de anómalos.

Transformación y recodificación de variables

Antes de avanzar, es necesario revisar si nuestras variables necesitan algún ajuste para que el análisis sea más fluido.

Transformar variables categóricas a variables 0-1.


Comenzaremos con la transformación de las variables categóricas (color y transparency) a dummies (0-1) para asegurar su compatibilidad con los modelos analíticos, como PCA.

	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	type	hardness	density
id1	1.51593	13.25	3.45	1.43	73.17	0.61	7.86	0	0.00	2	4	2.801783
id2	1.51711	12.89	3.62	1.57	72.96	0.61	8.11	0	0.00	2	4	2.600649
id3	1.52177	13.20	3.68	1.15	72.75	0.54	8.52	0	0.00	2	5	2.152241
id4	1.51818	13.72	0.00	0.56	74.45	0.00	10.99	0	0.00	2	7	2.289597
id5	1.51829	13.24	3.90	1.41	72.33	0.55	8.31	0	0.10	2	6	2.443725
id6	1.51665	13.14	3.45	1.76	72.48	0.60	8.38	0	0.17	3	4	2.504865
	colorCL	colorOT	colorWH	transparencyTL	transparencyTP							
id1	0	0	1		1					0		
id2	0	0	1		0					1		
id3	1	0	0		0					1		
id4	1	0	0		1					0		
id5	1	0	0		1					0		
id6	1	0	0		0					1		

Transformaciones para conseguir normalidad o simetría (Autoescalado)

Dado que las variables tienen escalas y unidades muy distintas, como el índice de refracción (RI) y el contenido de sodio (Na), es crucial ajustar todas las variables para que tengan una media de cero y una desviación típica de uno. Esto evita que las variables con valores numéricos más altos dominen el análisis en técnicas como el PCA.

Para determinar el método de normalización más adecuado, realizaremos una comparación visual entre la distribución original de las variables numéricas y su comportamiento tras aplicar una transformación logarítmica.



Como la transformación logarítmica sí “endereza” la distribución, comprobamos que podría resultar útil al emplear el PCA, pero por el momento estandarizamos las variables numéricas haciendo uso de Z-score.


Análisis de Componentes Principales

El PCA se ha aplicado con el objetivo de reducir la dimensionalidad de la base de datos, permitiendo identificar las relaciones entre las variables físico-químicas y la estructura de agrupación de las muestras de cristal.

Tratamiento de los datos

Se utilizaron todas las variables numéricas exceptuando el identificador `id` y `thermal_exp`(ya que se desconocía el significado de esta última y se eliminó). Los valores inconsistentes en la variable Potasio (K) fueron sustituidos por NA, permitiendo el uso del algoritmo NIPALS. Las variables categóricas (color y transparencia) ya fueron transformadas como variables dummy (0-1). Y ya se aplicó el centrado y escalado estándar a todas las variables para evitar que aquellas con magnitudes más grandes dominasen el análisis.


Selección del número de componentes principales



Como podemos observar en el scree plot, es recomendable elegir un total de 7 componentes principales (aquellas que superan la varianza media explicada por una PC, ilustrada por la línea roja). Para comprobar que es una correcta selección de componentes, podemos aplicar el criterio de Kaiser:

comp	eigenVal	percVar	cumPercVar
1	3.1315060	19.5719	19.5719
2	2.4611146	15.3820	34.9539
3	1.8133552	11.3335	46.2873
4	1.6405446	10.2534	56.5408
5	1.3912773	8.6955	65.2362
6	1.2211491	7.6322	72.8684
7	1.0001109	6.2507	79.1191
8	0.9575107	5.9844	85.1036

Aplicar el criterio de Kaiser supone elegir sólo las componentes con valores propios superiores a 1 (es decir, aquellas que explican mayor varianza que una variable escalada original, que tendría un valor propio de 1). La tabla evidencia que sólo las primeras siete componentes superan el 1. Estas siete componentes explican el 79.12% de la varianza acumulada. Aunque las primeras dos componentes capturan el 34.96% de la varianza, las componentes adicionales revelan patrones químicos importantes que no deben ignorarse en la caracterización de cristales. Así pues, repetimos el análisis con 7 componentes:




Al general estos gráficos, observamos como la séptima componente captura casi exclusivamente la variabilidad relacionada con hardness. Así pues, es necesario cuestionar su utilidad para el modelo, ya que no recoge mucha más información de lo que la variable original hardness ya aportaba por sí misma: PC7 no contribuye especialmente a la reducción de dimensionalidad (que es el objetivo del PCA). Por lo tanto es conveniente reducir el modelo a sólo 6 componentes.

Validación del modelo

Anómalos moderados


Comenzaremos con la detección de anómalos moderados utilizando SCR (Suma de Cuadrados Residual). Aquellas observaciones con valores muy altos de SCR estarán poco explicadas por el modelo, y por lo tanto serán consideradas anómalas. Para establecer el límite máximo de SCR con el que se considera que una observación sigue siendo válida empleamos dos niveles de confianza (95% y 99%).



Al elegir el límite más potente (aquel que detectará más anómalos) 95%, nos encontramos con 8 observaciones.

A partir de los gráficos de contribuciones SCR, podemos observar, por ejemplo, que para id150, id54 ó id146, el valor de colorOT es bajo y contribuye negativamente a su SCR. No obstante, esto no es motivo de preocupación, ya que colorOT sólo puede tomar 2 valores en nuestra base de datos (al ser una variable dummy) y estas observaciones simplemente están tomando el valor más bajo posible. No es un error o una anomalía.

No obstante, los valores altos que toman, por ejemplo, id132 e id145 para K y Ba respectivamente sí son un motivo de preocupación. Si representamos sus distribuciones (ya centradas y escaladas):



La primera variable (K) presenta dos picos: uno alrededor del 0.0, y otro sobre 0.6. Debido a la cantidad de observaciones que se acumulan sobre este valor, podría asumirse que esta tendencia de los valores de K a acercarse generalmente a uno de estos picos es una característica particular de esta variable y no un error o anomalía. No obstante, a partir de 0.6 aparecen unos cuantos valores muy elevados.


Para la variable Ba, aparece un único pico en 0.0, por lo que parece seguir, excluyendo pocos valores muy elevados, una distribución normal.

Ambas presentan colas a la derecha de sus picos, por lo que se supone que una transformación para mitigar la asimetría positiva (como $\log(x+1)$) podría ser útil para reducir el comportamiento anómalo de algunos valores.

Anómalos severos

A continuación, se detectarán los anómalos severos, es decir, aquellos que condicionan el modelo. Estos se caracterizarán por tener SCR bajos (es decir, sí que están explicados por el modelo porque condicionan el modelo a ellos mismos).

Repetimos el proceso anterior y encontramos una gran cantidad de anómalos severos, 11 concretamente.






Prácticamente todas las variables de composición química tienen valores anómalos severos asociados. Esto es muy preocupante. Podríamos aplicar la eliminación (pero perderíamos muchos datos), por lo que se procede a aplicar las transformaciones logarítmicas a las variables anteriores (K y Ba) y recalculamos el modelo PCA. También sería interesante aplicar la transformación a las otras variables químicas, pero estas no presentan asimetría positiva significativa, y por lo tanto no se ve justificada su aplicación. Tras aplicar las transformaciones, recalculamos los anómalos:

[1] "Cristales severos detectados (con transformación logarítmica):"

id145	id22	id31	id146	id86	id117	id132	id114
36.06737	31.72413	28.94065	25.81911	21.22603	20.56785	18.63612	17.83952
id52	id119	id135	id129	id4			
17.76061	15.33367	15.09663	13.80074	13.35059			

Nuestras transformaciones no han tenido un efecto positivo sobre la cantidad de anómalos (tanto moderados como severos) que aparecen en nuestra muestra, sino que de hecho han aumentado en cantidad. Así pues, esta estrategia de control de anómalos no es efectiva y se procederá a la eliminación de algunas de las observaciones anómalas (en concreto, 3 de cada categoría identificadas como más significativas), que se considerarán como errores: id145, id22 e id31 para los severos; id132, id150 e id145 para los moderados. Una vez eliminados, recalcularemos nuestro modelo PCA.





Por último, los gráficos de scores, y el concreto el que se genera con la comparación PC1:PC2, clasifican cada bservación por su tipo y revelan las características frecuentes para cada uno de ellos: el Tipo1 tendrá generalmente valores positivos para la PC1, y por lo tanto se esperarán materiales transparentes, de colores claros y con alto Mg y Fe. No obstante, sus

propiedades variarán más respecto a la PC2. Los elementos de Tipo3 y Tipo2 seguirán patrones similares. Los de Tipo4 y Tipo5, sin embargo, al encontrarse generalmente a la izquierda del eje de PC2, se esperará que expresen mayores valores de Ba, Na y Al, y que sean más coloridos. También expresarán variedad en las características de la PC2.

Reglas de asociación

Para poder aplicar las reglas de asociación a nuestros datos, es esencial la transformación del tipo de dato. Para hacerlo correctamente, es necesario hacer primero una función de discretización que permita convertir todas las variables numéricas en factores, y tras esto, convertir el tipo de dato en transactions para poder usar la librería arules y aplicar el algoritmo apriori.

Para facilitar la transformación, se vuelve a tomar la base de datos inicial. En la discretización, los niveles de cada elemento se separan en los grupos nivel bajo, medio, alto y ausencia (o en bajo y alto si solo hay dos valores posibles), para tener en cuenta que la falta de un material afectará a su composición y para evitar que se confunda la ausencia de un material con un nivel bajo de éste. Dureza y densidad se separarán en los niveles bajo, medio y alto.

Aplicación del algoritmo apriori

Por el interés para el análisis, las reglas seleccionadas se centran en las variables que aparecen con más frecuencia para los tipos de cristal como consecuentes, mostrando así las relaciones entre el uso de cada tipo de material y su composición o sus cualidades. Primero se hacen todas las reglas posibles que tengan como consecuente el tipo (y solamente el tipo), ordenándolas en función del lift que tengan. Además, se tiene en cuenta que para el tipo 3 solo hay 13 individuos, por lo que para que haya reglas que sean representativas de los cristales más comunes y también reglas que tengan en cuenta la menor cantidad de cristales de este tipo, se harán dos grupos de reglas con soportes diferentes.

```
set of 493 rules
```

```
rule length distribution (lhs + rhs):sizes
```

```
 2   3   4   5   6   7   8
 2  19  98 189 139  42   4
```

```
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 2.000  5.000  5.000  5.189  6.000  8.000
```

```
summary of quality measures:
```

support	confidence	coverage	lift
Min. :0.02198	Min. :0.8000	Min. :0.02198	Min. : 2.387
1st Qu.:0.05495	1st Qu.:0.8333	1st Qu.:0.06044	1st Qu.: 2.525
Median :0.06044	Median :0.8667	Median :0.06593	Median : 2.712
Mean :0.06368	Mean :0.8906	Mean :0.07209	Mean : 3.727
3rd Qu.:0.06593	3rd Qu.:0.9333	3rd Qu.:0.08242	3rd Qu.: 5.393
Max. :0.10989	Max. :1.0000	Max. :0.13736	Max. :14.000
count			

```
Min.    : 4.00
1st Qu.:10.00
Median  :11.00
Mean    :11.59
3rd Qu.:12.00
Max.    :20.00
```

mining info:

```
data ntransactions confidence
trans      182          0.8
```

Filtrado de las reglas

Se obtienen 493 reglas, por lo que es necesario pasar a un filtrado en el que se eliminen aquellas que sean redundantes y no aporten información.

Análisis de las reglas

En este primer análisis, se puede ver cómo todas las reglas de mayor lift tienen como consecuente el tipo 3, con un lift de 14, pero con soportes más bajos. Esto se deberá a que los cristales de tipo 3 son una minoría en la base de datos, pero todos los cristales de este tipo tienen composiciones muy similares, llegando así a este lift máximo. Para poder ver la influencia en todos los tipos, se buscan y analizan la primera regla de cada uno de los tipos, es decir, aquella con un mayor lift para cada uso de los cristales.

	lhs	rhs	support	confidence
[1]	{Mg=medio, Al=bajo}	=> {Type=1}	0.05494505	1
[2]	{RI=bajo, Mg=medio, K=alto, Fe=ausente}	=> {Type=2}	0.06593407	1
[3]	{RI=bajo, Al=medio, Ca=medio, Ba=ausente}	=> {Type=3}	0.02197802	1
[4]	{Ca=alto, Ba=ausente, color=OT}	=> {Type=4}	0.05494505	1
[5]	{Al=alto, Ba=medio}	=> {Type=5}	0.05494505	1

	coverage	lift	count
[1]	0.05494505	2.983607	10
[2]	0.06593407	3.033333	12
[3]	0.02197802	14.000000	4
[4]	0.05494505	8.666667	10
[5]	0.05494505	6.740741	10

Tras este análisis, se puede ver reflejado cómo de común es cada cristal: tipo 2, que es el más común, presenta reglas con mayor count y un lift reducido. Mientras que, en el caso excepcional del tipo 3, la regla obtenida tiene un lift muy superior a los otros (14), pero con menos soporte que el resto.

El tipo 1 se caracterizaría por una cantidad baja de Al y un nivel de Mg medio.

El tipo2, por un RI bajo, nivel medio de Mg, nivel alto de K y ausencia de Fe.

El tipo tres tendrá un RI bajo, cantidades medias de Al y Ca; y ausencia de Ba.

El tipo 4 tendría un Ca alto, una ausencia de Ba y un color opaco y, finalmente, el tipo 5 tendría un nivel alto de Al y un nivel medio de Ba.


Estas diferencias reflejan cómo, según la composición de un cristal, se obtienen distintas propiedades, y cómo, en función de estas propiedades se le dará un uso u otro a cada cristal.

Análisis Factorial de Correspondencias

Para aplicar el AFC Simple, es necesario contar con 2 factores que presenten un elevado número de categorías, lo que no se da en nuestro caso. Es por ello que optamos por aplicar el AFC múltiple sobre las 4 variables categóricas con las que contamos, representándolas en un espacio más reducido. Las variables (hardness (que podemos considerar categórica en este caso), color, transparency y type) quedan descritas en profundidad en la exploración inicial de la base de datos.



Número de dimensiones y modelo inicial

Generando un modelo AFC múltiple obtenemos un Scree Plot con 7 componentes cuya inercia representada supera la media total. No obstante, aplicamos el Elbow Method para seleccionar las tres primeras, pues resulta más apropiado para nuestro estudio. Queda explicada el 35% de la inercia total.



Interpretación del modelo

A continuación, se estudia la contribución de las variables a la formación de las componentes y la relación de las variables entre sí.




La dimensión 1 está principalmente asociada al color, concretamente a los cristales clasificados como Other y CL transparente, y a la categoría de transparencia opaca.

Respecto a la segunda componente, tiene contribuyentes menos intensos, destacando los niveles de transparencia TL y TP, la categoría 4 de tipo, y, de forma menos relevante, los niveles 2, 6 y 7 de dureza.

Por último, en la componente 3, destacan el tipo 3 (ventanas de vehículos con vidrio flotado), el nivel de dureza 7 y el color WH.

De los gráficos podemos deducir que el uso que se le da a un cristal está vinculado al nivel de transparencia del mismo, y que el color del cristal no se relaciona con su dureza. No obstante, para conocer mejor estas relaciones, se obtienen los siguientes gráficos.

Gráficos de variables y observaciones



Del gráfico de variables deducimos que existen diferencias significativas entre los tipos de cristal 4 y 5 (empleados para la fabricación envases y artículos de mesa, y en faros, respectivamente), lo que es lógico, mientras que los de tipo 1 y 2, ambos empleados en ventanas de edificios, sí tienen propiedad similares, sobre todo en cuanto al nivel de dureza y el color transparente.

Por otro lado, los niveles de dureza 2 y 7 están desvinculados del resto, entre los que sí existe una relación.

El gráfico de “color” reafirma lo comentado respecto a la contribución de los colores transparente, blanco y others a la primera componente, quedando representados de forma diferenciada de izquierda a derecha.

El gráfico de individuos de la derecha permite observar la relación entre la segunda componente y el nivel de transparencia, quedando especialmente bien representada la distinción entre los cristales TL translúcidos y los TP transparentes. Sin embargo, la tercera componente no tiene esta variable como contribuyente.