

Estudio sobre los Cristales

Mario Álvarez Martínez, Jorge Aranda Honrubia, Pablo de Puelles Carceles,
Julia Ruiz Picó, Cristina Tarraga Herrero (Grupo A1-10)

2026-03-14

Exploración y preparación de la BBDD [3 páginas máximo]

Nos encontramos ante una base de datos que registra la composición, densidad, dureza y otras características físicas de un grupo de cristales.

Descripción y naturaleza de las variables

	variable	tipo
RI	RI	numerical
Na	Na	numerical
Mg	Mg	numerical
Al	Al	numerical
Si	Si	numerical
K	K	numerical
Ca	Ca	numerical
Ba	Ba	numerical
Fe	Fe	numerical
Type	Type	numerical
hardness	hardness	numerical
color	color	categorical
transparency	transparency	categorical
density	density	numerical
thermal_exp	thermal_exp	numerical

Variables constantes o casi constantes

Queremos comprobar si existe alguna variable con variabilidad reducida o inexistente. Estas variables pueden considerarse constantes y por lo tanto no aportan información relevante para el análisis, por lo que deberían eliminarse. Sin embargo, ¿cómo puede evaluarse la variabilidad de una variable, y como se determina si esta es insuficiente?

Para las variables numéricas, podría calcular su desviación típica y se establecerá un valor mínimo para ella, pero como esta depende de las unidades de medida y de la magnitud de la variable, por lo que se prefiere usar el coeficiente de variación.

Para las variables categóricas, ya que no es posible extraer un parámetro de la variabilidad, se obtendrán dos tablas de frecuencias (absolutas y relativas) y comprobar si una sola categoría contiene la mayoría o totalidad de los datos.

RI	Na	Mg	Al
Min. :1.511	Min. :10.73	Min. :0.000	Min. :0.290
1st Qu.:1.517	1st Qu.:12.94	1st Qu.:1.750	1st Qu.:1.183
Median :1.518	Median :13.34	Median :3.465	Median :1.355

Mean :1.519	Mean :13.44	Mean :2.598	Mean :1.442
3rd Qu.:1.520	3rd Qu.:13.89	3rd Qu.:3.618	3rd Qu.:1.630
Max. :1.534	Max. :17.38	Max. :4.490	Max. :3.500
Si	K	Ca	Ba
Min. :69.81	Min. :0.0000	Min. : 5.430	Min. :0.0000
1st Qu.:72.19	1st Qu.:0.1100	1st Qu.: 8.325	1st Qu.:0.0000
Median :72.78	Median :0.5500	Median : 8.675	Median :0.0000
Mean :72.61	Mean :0.4932	Mean : 9.047	Mean :0.1895
3rd Qu.:73.07	3rd Qu.:0.6000	3rd Qu.: 9.418	3rd Qu.:0.0000
Max. :75.41	Max. :6.2100	Max. :16.190	Max. :3.1500
Fe	Type	hardness	density
Min. :0.00000	Min. :1.000	Min. :1.000	Min. :1.991
1st Qu.:0.00000	1st Qu.:1.000	1st Qu.:2.000	1st Qu.:2.358
Median :0.00000	Median :2.000	Median :4.000	Median :2.487
Mean :0.05478	Mean :2.412	Mean :3.758	Mean :2.499
3rd Qu.:0.09750	3rd Qu.:4.000	3rd Qu.:5.000	3rd Qu.:2.617
Max. :0.51000	Max. :5.000	Max. :7.000	Max. :3.028
thermal_exp			
Min. : 5.197			
1st Qu.: 7.971			
Median : 9.033			
Mean : 9.018			
3rd Qu.:10.046			
Max. :12.172			

RI	Si	Na	density	thermal_exp	Ca
0.002089285	0.011297771	0.063155740	0.077034630	0.165150703	0.165275035
Al	hardness	Mg	Type	K	Fe
0.355153852	0.507853168	0.571899760	0.592820556	1.420877170	1.759191850
Ba					
2.735458238					

color transparency	
[1,]	124 13
[2,]	27 41
[3,]	31 128

color transparency	
[1,]	68.13 7.14
[2,]	14.84 22.53
[3,]	17.03 70.33

Por ahora se decide no eliminar ninguna variable, ya que ninguna de ellas presenta un comportamiento constante o casi constante. Se considera que todas pueden aportar información valiosa al análisis.

Variable de significado desconocido

Para la variable thermal_exp, no se conoce su significado concreto, por lo que se decide su eliminación.

Análisis descriptivo


Valores inconsistentes o anómalos

A continuación se analiza si alguna de las variables presenta valores inconsistentes, es decir, valores que no son posibles dentro del rango de definición de la variable. Conviene plantear si estos datos se deben a un error

(en cuyo caso se sustituyen por NA), o si son valores posibles pero extremos que podrían aportar información interesante sobre el comportamiento de la variable.

Por un lado, el estudio de los valores anómalos de las variables numéricas parte de la representación de cada una de ellas en un diagrama de caja y bigotes, al adoptar el análisis una perspectiva univariante. Como se puede deducir a partir de los resultados del apartado anterior, observando los valores medios para cada variable, los datos se encuentran en rangos diferentes.


Es por ello que, con el objetivo de representar todos los boxplots juntos y analizar la presencia de valores atípicos en términos relativos evitando distorsiones en el gráfico, estandarizamos previamente las variables haciendo uso de la función “scale”.



De esta forma, a primera vista identificamos valores atípicos en la mayoría de las variables, siguiendo estas distribuciones asimétricas.

Destacan valores extremos en las variables K y Ba, que corresponden al contenido en potasio y bario que presentan los cristales. Para analizar mejor estas propiedades, las representamos individualmente en gráficos de caja y bigotes e histogramas.

Histogram of data\$K



```

0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09 0.1 0.11 0.12 0.13 0.14 0.15 0.16
28 1 1 2 1 4 1 3 2 1 4 2 2 2 1 1
0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
1 1 3 3 1 1 2 1 1 1 1 1 1 2 1 3
0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59 0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
3 1 4 5 9 11 10 6 11 7 5 5 3 2 3 3
0.69 0.7 0.72 0.76 0.81 0.97 1.41 1.46 1.68 1.76 2.7 6.21
1 1 1 2 1 1 1 1 1 1 1 2

```

A partir del histograma podemos deducir que la proporción relativa de potasio en los cristales se mueve entre valores de 0 y 3, por lo que interpretamos los dos valores extremos 6.21 como errores (valores inconsistentes) y los reemplazamos por valores faltantes (NA).

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
0.0000	0.1100	0.5500	0.4297	0.6000	2.7000	2


```

0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09 0.1 0.11 0.12 0.13 0.14 0.15 0.16
28 1 1 2 1 4 1 3 2 1 4 2 2 2 1 1
0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
1 1 3 3 1 1 2 1 1 1 1 1 1 2 1 3
0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59 0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
3 1 4 5 9 11 10 6 11 7 5 5 3 2 3 3
0.69 0.7 0.72 0.76 0.81 0.97 1.41 1.46 1.68 1.76 2.7
1 1 1 2 1 1 1 1 1 1 1

```


Respecto al contenido en bario, al hacer la representación podemos deducir que se trata de un elemento


presente en los cristales en proporción muy dispar, quedando reflejado en la asimetría de la distribución. No interpretamos los valores como inconsistentes, por lo que mantenemos los valores anómalos en la base de datos, como reflejo del comportamiento real de la variable.



0	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09	0.1	0.11	0.12	0.13	0.14	0.15	0.16
28	1	1	2	1	4	1	3	2	1	4	2	2	2	1	1
0.17	0.18	0.19	0.23	0.31	0.32	0.33	0.35	0.37	0.38	0.39	0.44	0.45	0.47	0.49	0.51
1	1	3	3	1	1	2	1	1	1	1	1	1	2	1	3
0.52	0.53	0.54	0.55	0.56	0.57	0.58	0.59	0.6	0.61	0.62	0.64	0.65	0.66	0.67	0.68
3	1	4	5	9	11	10	6	11	7	5	5	3	2	3	3
0.69	0.7	0.72	0.76	0.81	0.97	1.41	1.46	1.68	1.76	2.7					
1	1	1	2	1	1	1	1	1	1	1					

Para el análisis de las variables categóricas, optamos por un resumen descriptivo representando las frecuencias de cada valor en un gráfico de barras, al tener pocas categorías diferentes.





No identificamos ningún valor inconsistente en los datos de color y transparencia de los cristales.

Valores faltantes

Transformación y recodificación de variables

Antes de avanzar, es necesario revisar si nuestras variables necesitan algún ajuste para que el análisis sea más fluido. En este apartado evaluaremos si la composición química y las características cualitativas del cristal, como el color, están en el formato óptimo. Veremos si es mejor reagrupar algunas categorías pequeñas o crear variables binarias que nos ayuden a simplificar la información. No buscamos cambiar los datos por cambiar, sino adaptarlos para que la base de datos esté bien alineada con el foco de nuestro estudio y responda mejor cuando empecemos a clasificar los tipos de cristales.

Transformar variables categóricas a variables 0-1.

Comenzaremos con la transformación de las variables categóricas para asegurar su compatibilidad con los modelos analíticos. Convertiremos las categorías de los tipos de colores o transparencia de los cristales en variables numéricas de 0 y 1. Esta recodificación es fundamental porque transformare la información cualitativa en datos cuantitativos que los algoritmos de clasificación o PCA puedan procesar eficientemente, permitiéndonos integrar todas las propiedades del cristal en un único conjunto de datos numérico.

	colorCL	colorOT	colorWH	transparencyTL	transparencyTP
id1	0	0	1	1	0
id2	0	0	1	0	1
id3	1	0	0	0	1
id4	1	0	0	1	0

id5	1	0	0	1	0
id6	1	0	0	0	1

Esta matriz la añadiremos como columnas nuevas a la base de datos para cada tipo de color y nivel de transparencia. En cada fila (cristal), se marcará con un ‘1’ la columna que corresponda a su característica real, y con un ‘0’ aquellas que no apliquen, permitiendo así que el modelo identifique sus propiedades cualitativas mediante valores numéricos.

	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	Type	hardness	density
id1	1.51593	13.25	3.45	1.43	73.17	0.61	7.86	0	0.00	2	4	2.801783
id2	1.51711	12.89	3.62	1.57	72.96	0.61	8.11	0	0.00	2	4	2.600649
id3	1.52177	13.20	3.68	1.15	72.75	0.54	8.52	0	0.00	2	5	2.152241
id4	1.51818	13.72	0.00	0.56	74.45	0.00	10.99	0	0.00	2	7	2.289597
id5	1.51829	13.24	3.90	1.41	72.33	0.55	8.31	0	0.10	2	6	2.443725
id6	1.51665	13.14	3.45	1.76	72.48	0.60	8.38	0	0.17	3	4	2.504865

	colorCL	colorOT	colorWH	transparencyTL	transparencyTP
id1	0	0	1	1	0
id2	0	0	1	0	1
id3	1	0	0	0	1
id4	1	0	0	1	0
id5	1	0	0	1	0
id6	1	0	0	0	1

Tras esta transformación, disponemos de una base de datos completamente numérica y mejor estructurada, garantizando la compatibilidad necesaria para aplicar con precisión técnicas avanzadas como PCA y clustering en los próximos análisis.


Reagrupar categorías poco frecuentes

Tras analizar la distribución de la variable color, se ha observado que la mayoría de las observaciones se concentran en dos categorías principales, existiendo una tercera clase denominada ‘Others’ que agrupa eficientemente las tonalidades minoritarias. Dado que esta estructura ya garantiza que ninguna categoría tenga una frecuencia insignificante que pudiera desestabilizar los modelos matemáticos posteriores, se ha decidido mantener la variable tal como está, procediendo directamente a su transformación en variables dummy sin necesidad de realizar reagrupaciones adicionales.


Transformaciones para conseguir normalidad o simetría (Autoescalado)

Con la base de datos ya convertida a un formato puramente numérico, el siguiente paso fundamental es la normalización (o estandarización) de las variables. Dado que características como el índice de refracción (RI) y el contenido de sodio (Na) tienen escalas y unidades de medida muy distintas, es crucial ajustar todas las variables para que tengan una media de cero y una desviación estándar de uno. Esto evita que las variables con valores numéricos más altos dominen artificialmente los cálculos de distancia, asegurando que técnicas como el PCA y el clustering ponderen correctamente la influencia de todas las propiedades del cristal, independientemente de su magnitud original.

Para determinar el método de normalización más adecuado, realizaremos una comparación visual entre la distribución original de las variables numéricas y su comportamiento tras aplicar una transformación logarítmica. Mediante gráficos de densidad, evaluaremos qué enfoque corrige mejor la asimetría de los datos, asegurando que la estructura resultante sea óptima para los análisis multivariantes posteriores.



Densidad Na (Transformada log2)



```

      RI      Na      Mg      Al      Si
-1.691959e-14  6.970300e-16 -1.404173e-16 -1.319057e-16 -8.187275e-15
      K      Ca      Ba      Fe
      NA  4.716160e-17 -9.378945e-18 -2.104544e-17

```

```

RI Na Mg Al Si  K Ca Ba Fe
1  1  1  1  1 NA  1  1  1

```

La necesidad de estandarizar las variables mediante un Z-score (ajustando media a cero y desviación estándar a uno) radica en la disparidad de escalas y unidades de medida entre los componentes químicos del cristal. Este paso es crucial para evitar que variables con valores absolutos elevados dominen el análisis, garantizando que el PCA y el Clustering detecten patrones basados en la verdadera relevancia estadística de cada característica, no solo en su magnitud.

character(0)

[1] "Medias (deben ser casi 0):"

```

      RI      Na      Mg      Al      Si
      0      0      0      0      0
      K      Ca      Ba      Fe      Type
      NA      0      0      0      0
hardness    density    colorCL    colorOT    colorWH
      0      0      0      0      0
transparencyTL transparencyTP
      0      0

```

[1] "Desviaciones típicas (deben ser 1):"

```

      RI      Na      Mg      Al      Si

```

1	1	1	1	1
K	Ca	Ba	Fe	Type
NA	1	1	1	1
hardness	density	colorCL	colorOT	colorWH
1	1	1	1	1
transparencyTL	transparencyTP			
1	1			

Tras finalizar la estandarización de las variables, se ha verificado correctamente centrando y escalando nuestras variables numéricas obteniendo una media de cero y una desviación de uno. Este resultado confirma que la base de datos está perfectamente equilibrada y optimizada para las técnicas de PCA y clustering.

Análisis de Componentes Principales [5 páginas máximo]

El Análisis de Componentes Principales se ha aplicado con el objetivo de reducir la dimensionalidad de la base de datos, permitiendo identificar las relaciones entre las variables físico-químicas y la estructura de agrupación de las muestras de cristal.


Tratamiento de los datos

La fase previa al análisis multivariante ha consistido en un acondicionamiento riguroso de la base de datos para asegurar la estabilidad de los cálculos. En primer lugar, se ha llevado a cabo una criba técnica de las dimensiones disponibles, integrando en el estudio todas las variables físico-químicas a excepción de aquellas que, como `thermal_exp` o el identificador `id`, no aportan variabilidad o información relevante para la discriminación de las muestras. Este proceso garantiza que el modelo resultante se centre exclusivamente en los descriptores con capacidad analítica.

En cuanto a la integridad de los datos, se ha aplicado una transformación específica sobre la variable Potasio (K) para gestionar las lecturas que presentaban inconsistencias manifiestas. Estos valores han sido sustituidos por datos faltantes (NA), una decisión que permite el uso del algoritmo NIPALS en fases posteriores para estimar las componentes de forma iterativa sin necesidad de descartar las muestras afectadas. De igual modo, las variables cualitativas se han codificado mediante variables dummy, permitiendo que la información sobre el color o la transparencia pueda ser procesada numéricamente por el modelo.

Para finalizar el tratamiento, se ha aplicado un centrado y escalado estándar a la matriz de datos. Este paso es fundamental para neutralizar las diferencias de magnitud y unidades de medida entre las variables, como ocurre entre el Índice de Refracción y las concentraciones de elementos químicos. Al transformar cada variable para que presente media cero y desviación típica unitaria, se consigue que todas las propiedades del cristal tengan el mismo peso relativo en la construcción del espacio multidimensional, evitando que las variables con valores numéricos más elevados dominen artificialmente el análisis. ## Selección del número de componentes principales Para determinar la dimensionalidad óptima del modelo, se ha analizado el gráfico de sedimentación o Scree Plot (Figura X). En este gráfico se representa la varianza retenida por cada componente frente a la varianza media (marcada por la línea roja).

Como se puede observar, existen cuatro componentes que se sitúan por encima o en el límite del criterio de Kaiser (varianza propia > 1). A partir de la cuarta componente, la curva muestra una pendiente mucho más suave, indicando que las dimensiones adicionales aportarían mayoritariamente ruido al modelo. Por tanto, se ha decidido retener estas cuatro dimensiones para el análisis.




Esta decisión se ratifica mediante el análisis de la varianza acumulada (Tabla 1). La retención de cuatro componentes permite explicar un 83.49% de la información original, superando ampliamente el umbral del 80% que suele considerarse satisfactorio en estudios de caracterización química de materiales.

comp	eigenVal	percVar	cumPercVar
1	3.836032	22.5649	22.5649
2	2.473282	14.5487	37.1136
3	1.826782	10.7458	47.8594
4	1.660896	9.7700	57.6294


Para facilitar la interpretación del espacio multidimensional generado, se ha optado por una representación distribuida en dos bloques factoriales diferenciados. Inicialmente, la visualización conjunta de todas las dimensiones y etiquetas generaba una saturación de información que impedía distinguir los patrones y las identidades de las muestras. Para solucionar este problema técnico, se ha decidido dividir la representación en dos paneles independientes y aplicar un filtrado mediante el parámetro labelTop. Esta técnica permite que el software solo rotule de forma automática el 2% de las observaciones con mayor contribución, logrando que los gráficos respiren y que los nombres de los cristales más relevantes sean legibles sin solaparse entre sí.

En el análisis del primer bloque, que comprende la primera y segunda componente principal y explica más de la mitad de la varianza total (56.64%), se observa que la primera dimensión actúa fundamentalmente como un eje de densidad y refracción. En este eje, el índice de refracción (RI) y el calcio (Ca) presentan las mayores cargas positivas, marcando la tendencia principal de la base de datos. Por su parte, la segunda componente establece una diferenciación química clara, donde el magnesio (Mg) se sitúa con una correlación positiva máxima en oposición directa al aluminio (Al) y al bario (Ba), permitiendo discriminar las muestras según estos aditivos.



La proyección de las muestras en este primer plano revela la existencia de observaciones que se segregan de manera significativa del grupo central, destacando especialmente los individuos identificados como 107 y 108. Estas muestras presentan posiciones extremas en la dirección definida por el bario y el aluminio, lo que denota un perfil químico singular respecto al promedio y sugiere que podrían pertenecer a categorías de cristal con aplicaciones industriales específicas que requieren propiedades ópticas o estructurales diferenciadas.



El estudio del segundo bloque, correspondiente a la tercera y cuarta componente principal, justifica la decisión de ampliar la dimensionalidad del modelo, ya que estas dimensiones revelan la variabilidad de los elementos minoritarios que queda oculta en los ejes mayoritarios. En este plano, que aporta un 26.85% de varianza adicional, la tercera componente se encuentra condicionada casi en su totalidad por las variaciones del potasio (K), mientras que la cuarta componente captura la variabilidad específica del hierro (Fe).



En esta proyección emergen muestras como la 185 y la 202, que no resultaban especialmente llamativas en el análisis de las primeras componentes. Su aparición como puntos aislados en este segundo plano se debe a concentraciones atípicas de potasio y hierro respectivamente, lo que demuestra que la estrategia de dividir el análisis en bloques y utilizar un etiquetado selectivo es necesaria para detectar matices químicos críticos que, de otro modo, quedarían enmascarados por la densidad de los datos.

Validación del modelo

Comenzaremos con la detección de anomalos moderados utilizando scr




```
[1] "Cristales moderados detectados:"
```

```
      id145      id132      id22      id146      id150      id117      id129
55.75899 48.50774 44.12532 41.29360 30.31903 27.77917 26.99538
```

Vemos que falla id108, id107, id 112

There are no severe outliers in the data or they were not computed.

There are 3 moderate outliers in the data provided.



\$contribT2

NULL

\$contribRSS

	RI	Na	Mg	Al	Si	K	Ca
id145	0.8152893	-19.078916	0.00726606	5.834723	-4.174025	11.92666	-0.4428030
id132	1.8800879	-5.615534	-6.00895138	-3.495021	5.412693	59.18968	2.5563359
id22	1.9814338	-1.921797	3.81658214	7.680427	-40.972661	24.09233	-0.3918378
	Ba	Fe	Type	hardness	density	colorCL	
id145	46.8954866	3.1087903	-1.144968	2.09089319	-1.94948204	0.28177383	
id132	-0.2423758	0.2341431	3.456016	-0.90659961	-0.05482062	0.03235272	
id22	11.4776056	0.2284863	-2.658178	-0.08461649	0.36877206	-0.42713308	
	colorOT	colorWH	transparencyTL	transparencyTP			
id145	-1.415844	0.21819879	0.5819256	-0.03295364			
id132	3.776705	-4.24559403	-0.6300321	2.26306114			
id22	1.060029	-0.02670145	-0.2180782	-2.59332780			

Interpretación del modelo

Conclusiones

Tras la ejecución y validación del modelo, se concluye que la variabilidad química y física de la base de datos de cristales puede sintetizarse eficazmente en cuatro dimensiones principales. La estructura obtenida demuestra que el Índice de Refracción y el Calcio son los factores determinantes de la varianza mayoritaria, mientras que elementos como el Magnesio y el Bario actúan como los principales diferenciadores entre tipos de vidrio.

Una conclusión crítica de este análisis es la relevancia de los componentes minoritarios. De no haber retenido la tercera y cuarta componente, la influencia del Potasio y el Hierro habría quedado enmascarada, impidiendo la detección de muestras singulares como la 185 y la 202. Por tanto, el modelo no solo permite una reducción de la dimensionalidad, sino que actúa como una herramienta de pre-clasificación que segrega perfiles químicos específicos. Estos hallazgos establecen una base sólida para las posteriores fases de agrupación (clustering), donde se espera que estas relaciones químicas definan la formación de clústeres bien diferenciados según el uso o procedencia del cristal.

Reglas de asociación [OPCIONAL. 2 páginas máximo]

Análisis Factorial de Correspondencias [OPCIONAL. 2 páginas máximo]