

Estudio sobre los Cristales

Mario Álvarez Martínez, Jorge Aranda Honrubia, Pablo de Puelles Carceles, Julia Ruiz Picó, Cristina T

2026-03-04

Exploración y preparación de la BBDD [3 páginas máximo]

Nos encontramos ante una base de datos que registra la composición, densidad, dureza y otras características físicas de un grupo de cristales.

Descripción y naturaleza de las variables

##	tipo
## RI	numerical
## Na	numerical
## Mg	numerical
## Al	numerical
## Si	numerical
## K	numerical
## Ca	numerical
## Ba	numerical
## Fe	numerical
## Type	numerical
## hardness	numerical
## color	categorical
## tranparency	categorical
## density	numerical
## thermal_exp	numerical

Variables constantes o casi constantes

Queremos comprobar si existe alguna variable con variabilidad reducida o inexistente. Estas variables pueden considerarse constantes y por lo tanto no aportan información relevante para el análisis, por lo que deberían eliminarse. Sin embargo, ¿cómo puede evaluarse la variabilidad de una variable, y como se determina si esta es insuficiente?

Para las variables numéricas, podría calcular su desviación típica y se establecerá un valor mínimo para ella, pero como esta depende de las unidades de medida y de la magnitud de la variable, por lo que se prefiere usar el coeficiente de variación.

Para las variables categóricas, ya que no es posible extraer un parámetro de la variabilidad, se obtendrán dos tablas de frecuencias (absolutas y relativas) y comprobar si una sola categoría contiene la mayoría o totalidad de los datos.

```
## < table of extent 0 x 0 >
## numeric(0)
## named integer(0)
```

```
## named numeric(0)
```

Por ahora se decide no eliminar ninguna variable, ya que ninguna de ellas presenta un comportamiento constante o casi constante. Se considera que todas pueden aportar información valiosa al análisis.

Análisis descriptivo


Valores inconsistentes o anómalos

A continuación se analiza si alguna de las variables presenta valores inconsistentes, es decir, valores que no son posibles dentro del rango de definición de la variable. Conviene plantear si estos datos se deben a un error (en cuyo caso se sustituyen por NA), o si son valores posibles pero extremos que podrían aportar información interesante sobre el comportamiento de la variable.

Por un lado, el estudio de los valores anómalos de las variables numéricas parte de la representación de cada una de ellas en un diagrama de caja y bigotes, al adoptar el análisis una perspectiva univariante. Como se puede deducir a partir de los resultados del apartado anterior, observando los valores medios para cada variable, los datos se encuentran en rangos diferentes.

Es por ello que, con el objetivo de representar todos los boxplots juntos y analizar la presencia de valores atípicos en términos relativos evitando distorsiones en el gráfico, estandarizamos previamente las variables haciendo uso de la función “scale”.


```
# 1. Seleccionamos SOLO las columnas que son realmente números en el dataset 'data'  
# Esto evita depender de 'descData', que parece estar dando problemas  
data_solo_numeros <- data[, sapply(data, is.numeric)]  
  
# 2. Eliminamos columnas que tengan TODO valores NA (si las hay)  
data_solo_numeros <- data_solo_numeros[, colSums(!is.na(data_solo_numeros)) > 0]  
  
# 3. Graficamos con un control de margen para que se vean los nombres  
par(mar = c(9, 4, 2, 2))  
boxplot(scale(data_solo_numeros), las = 2, main = "Detección de Atípicos (Escalaado)")
```



De esta forma, a primera vista identificamos valores atípicos en la mayoría de las variables, siguiendo estas distribuciones asimétricas.

Destacan valores extremos en las variables K y Ba, que corresponden al contenido en potasio y bario que presentan los cristales. Para analizar mejor estas propiedades, las representamos individualmente en gráficos de caja y bigotes e histogramas.

Histogram of data\$K



```
##
##      0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09  0.1 0.11 0.12 0.13 0.14 0.15 0.16
##    28   1   1   2   1   4   1   3   2   1   4   2   2   2   1   1
## 0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
##   1   1   3   3   1   1   2   1   1   1   1   1   1   2   1   3
## 0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59  0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
##   3   1   4   5   9  11  10   6  11   7   5   5   3   2   3   3
## 0.69  0.7 0.72 0.76 0.81 0.97 1.41 1.46 1.68 1.76  2.7 6.21
##   1   1   1   2   1   1   1   1   1   1   1   1   2
```

A partir del histograma podemos deducir que la proporción relativa de potasio en los cristales se mueve entre valores de 0 y 3, por lo que interpretamos los dos valores extremos 6.21 como errores (valores inconsistentes) y los reemplazamos por valores faltantes (NA).

```
data[which(data$K > 3), "K"] = NA
summary(data$K)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NA's
## 0.0000  0.1100   0.5500   0.4297  0.6000   2.7000         2
```


```
table(data$K)
```

```
##
##      0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09  0.1 0.11 0.12 0.13 0.14 0.15 0.16
##    28   1   1   2   1   4   1   3   2   1   4   2   2   2   1   1
## 0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
##   1   1   3   3   1   1   2   1   1   1   1   1   1   2   1   3
## 0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59  0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
```

```
##      3      1      4      5      9      11      10      6      11      7      5      5      3      2      3      3
## 0.69  0.7  0.72  0.76  0.81  0.97  1.41  1.46  1.68  1.76  2.7
##      1      1      1      2      1      1      1      1      1      1      1
```


Respecto al contenido en bario, al hacer la representación podemos deducir que se trata de un elemento presente en los cristales en proporción muy dispar, quedando reflejado en la asimetría de la distribución. No interpretamos los valores como inconsistentes, por lo que mantenemos los valores anómalos en la base de datos, como reflejo del comportamiento real de la variable.


Histogram of data\$Ba



```
##
##      0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09 0.1 0.11 0.12 0.13 0.14 0.15 0.16
##    28   1   1   2   1   4   1   3   2   1   4   2   2   2   1   1
## 0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
##     1   1   3   3   1   1   2   1   1   1   1   1   1   2   1   3
## 0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59 0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
##     3   1   4   5   9   11   10   6   11   7   5   5   3   2   3   3
## 0.69 0.7 0.72 0.76 0.81 0.97 1.41 1.46 1.68 1.76 2.7
##     1   1   1   2   1   1   1   1   1   1   1
```

Para el análisis de las variables categóricas, optamos por un resumen descriptivo representando las frecuencias de cada valor en un gráfico de barras, al tener pocas categorías diferentes.





No identificamos ningún valor inconsistente en los datos de color y transparencia de los cristales.

Valores faltantes

Transformación y recodificación de variables

Antes de avanzar, es necesario revisar si nuestras variables necesitan algún ajuste para que el análisis sea más fluido. En este apartado evaluaremos si la composición química y las características cualitativas del cristal, como el color, están en el formato óptimo. Veremos si es mejor reagrupar algunas categorías pequeñas o crear variables binarias que nos ayuden a simplificar la información. No buscamos cambiar los datos por cambiar, sino adaptarlos para que la base de datos esté bien alineada con el foco de nuestro estudio y responda mejor cuando empecemos a clasificar los tipos de cristales.

Transformar variables categóricas a variables 0-1.

Comenzaremos con la transformación de las variables categóricas para asegurar su compatibilidad con los modelos analíticos. Convertiremos las categorías de los tipos de colores o transparencia de los cristales en variables numéricas de 0 y 1. Esta recodificación es fundamental porque transformare la información cualitativa en datos cuantitativos que los algoritmos de clasificación o PCA puedan procesar eficientemente, permitiéndonos integrar todas las propiedades del cristal en un único conjunto de datos numérico.

##	colorCL	colorOT	colorWH	transparencyTL	transparencyTP
## id1	0	0	1	1	0
## id2	0	0	1	0	1
## id3	1	0	0	0	1
## id4	1	0	0	1	0

```
## id5      1      0      0      1      0
## id6      1      0      0      0      1
```

Esta matriz la añadiremos como columnas nuevas a la base de datos para cada tipo de color y nivel de transparencia. En cada fila (cristal), se marcará con un ‘1’ la columna que corresponda a su característica real, y con un ‘0’ aquellas que no apliquen, permitiendo así que el modelo identifique sus propiedades cualitativas mediante valores numéricos.

```
##      RI      Na      Mg      Al      Si      K      Ca Ba      Fe Type hardness density
## id1 1.51593 13.25 3.45 1.43 73.17 0.61 7.86 0 0.00 2      4 2.801783
## id2 1.51711 12.89 3.62 1.57 72.96 0.61 8.11 0 0.00 2      4 2.600649
## id3 1.52177 13.20 3.68 1.15 72.75 0.54 8.52 0 0.00 2      5 2.152241
## id4 1.51818 13.72 0.00 0.56 74.45 0.00 10.99 0 0.00 2      7 2.289597
## id5 1.51829 13.24 3.90 1.41 72.33 0.55 8.31 0 0.10 2      6 2.443725
## id6 1.51665 13.14 3.45 1.76 72.48 0.60 8.38 0 0.17 3      4 2.504865
##      thermal_exp colorCL colorOT colorWH tranparencyTL tranparencyTP
## id1 10.745921      0      0      1      1      0
## id2 7.941957      0      0      1      0      1
## id3 9.880037      1      0      0      0      1
## id4 11.419015      1      0      0      1      0
## id5 6.071586      1      0      0      1      0
## id6 10.607987      1      0      0      0      1
```

Tras esta transformación, disponemos de una base de datos completamente numérica y mejor estructurada, garantizando la compatibilidad necesaria para aplicar con precisión técnicas avanzadas como PCA y clustering en los próximos análisis.


Reagrupar categorías poco frecuentes

Tras analizar la distribución de la variable color, se ha observado que la mayoría de las observaciones se concentran en dos categorías principales, existiendo una tercera clase denominada ‘Others’ que agrupa eficientemente las tonalidades minoritarias. Dado que esta estructura ya garantiza que ninguna categoría tenga una frecuencia insignificante que pudiera desestabilizar los modelos matemáticos posteriores, se ha decidido mantener la variable tal como está, procediendo directamente a su transformación en variables dummy sin necesidad de realizar reagrupaciones adicionales.


Transformaciones para conseguir normalidad o simetría (Autoescalado)

Con la base de datos ya convertida a un formato puramente numérico, el siguiente paso fundamental es la normalización (o estandarización) de las variables. Dado que características como el índice de refracción (RI) y el contenido de sodio (Na) tienen escalas y unidades de medida muy distintas, es crucial ajustar todas las variables para que tengan una media de cero y una desviación estándar de uno. Esto evita que las variables con valores numéricos más altos dominen artificialmente los cálculos de distancia, asegurando que técnicas como el PCA y el clustering ponderen correctamente la influencia de todas las propiedades del cristal, independientemente de su magnitud original.

Para determinar el método de normalización más adecuado, realizaremos una comparación visual entre la distribución original de las variables numéricas y su comportamiento tras aplicar una transformación logarítmica. Mediante gráficos de densidad, evaluaremos qué enfoque corrige mejor la asimetría de los datos, asegurando que la estructura resultante sea óptima para los análisis multivariantes posteriores.



Densidad Na (Transformada log2)



```
##          RI          Na          Mg          Al          Si
## -1.691959e-14  6.970300e-16 -1.404173e-16 -1.319057e-16 -8.187275e-15
##          K          Ca          Ba          Fe
##          NA  4.716160e-17 -9.378945e-18 -2.104544e-17
```

```
## RI Na Mg Al Si  K Ca Ba Fe
##  1  1  1  1  1 NA  1  1  1
```

La necesidad de estandarizar las variables mediante un Z-score (ajustando media a cero y desviación estándar a uno) radica en la disparidad de escalas y unidades de medida entre los componentes químicos del cristal. Este paso es crucial para evitar que variables con valores absolutos elevados dominen el análisis, garantizando que el PCA y el Clustering detecten patrones basados en la verdadera relevancia estadística de cada característica, no solo en su magnitud.

```
## [1] "Medias (deben ser casi 0):"
```

```
##          RI          Na          Mg          Al          Si
##          0          0          0          0          0
##          K          Ca          Ba          Fe          Type
##          NA          0          0          0          0
## hardness      density  thermal_exp      colorCL      colorOT
##          0          0          0          0          0
## colorWH transparencyTL transparencyTP
##          0          0          0
```

```
## [1] "Desviaciones típicas (deben ser 1):"
```

```
##          RI          Na          Mg          Al          Si
##          1          1          1          1          1
```

##	K	Ca	Ba	Fe	Type
##	NA	1	1	1	1
##	hardness	density	thermal_exp	colorCL	colorOT
##	1	1	1	1	1
##	colorWH	tranparencyTL	tranparencyTP		
##	1	1	1		

Tras finalizar la estandarización de las variables, se ha verificado correctamente centrando y escalando nuestras variables numéricas obteniendo una media de cero y una desviación de uno. Este resultado confirma que la base de datos está perfectamente equilibrada y optimizada para las técnicas de PCA y clustering.

Análisis de Componentes Principales [5 páginas máximo]

Tratamiento de los datos

Selección del número de componentes principales

Validación del modelo

Interpretación del modelo

Conclusiones

Reglas de asociación [OPCIONAL. 2 páginas máximo]

Análisis Factorial de Correspondencias [OPCIONAL. 2 páginas máximo]