

Estudio sobre los Cristales

Mario Álvarez Martínez, Jorge Aranda Honrubia, Pablo de Puelles Carceles,
Julia Ruiz Picó, Cristina Tarraga Herrero (Grupo A1-10)

2026-04-09

Exploración y preparación de la BBDD [3 páginas máximo]

Nos encontramos ante una base de datos que registra la composición, densidad, dureza y otras características físicas de un grupo de cristales.

Descripción y naturaleza de las variables

	variable	tipo
RI	RI	numerical
Na	Na	numerical
Mg	Mg	numerical
Al	Al	numerical
Si	Si	numerical
K	K	numerical
Ca	Ca	numerical
Ba	Ba	numerical
Fe	Fe	numerical
Type	Type	numerical
hardness	hardness	numerical
color	color	categorical
transparency	transparency	categorical
density	density	numerical
thermal_exp	thermal_exp	numerical

Variables constantes o casi constantes

Queremos comprobar si existe alguna variable con variabilidad reducida o inexistente. Estas variables pueden considerarse constantes y por lo tanto no aportan información relevante para el análisis, por lo que deberían eliminarse. Sin embargo, ¿cómo puede evaluarse la variabilidad de una variable, y como se determina si esta es insuficiente?

Para las variables numéricas, podría calcular su desviación típica y se establecerá un valor mínimo para ella, pero como esta depende de las unidades de medida y de la magnitud de la variable, por lo que se prefiere usar el coeficiente de variación.

Para las variables categóricas, ya que no es posible extraer un parámetro de la variabilidad, se obtendrán dos tablas de frecuencias (absolutas y relativas) y comprobar si una sola categoría contiene la mayoría o totalidad de los datos.

RI	Na	Mg	Al
Min. :1.511	Min. :10.73	Min. :0.000	Min. :0.290
1st Qu.:1.517	1st Qu.:12.94	1st Qu.:1.750	1st Qu.:1.183
Median :1.518	Median :13.34	Median :3.465	Median :1.355

Mean :1.519	Mean :13.44	Mean :2.598	Mean :1.442
3rd Qu.:1.520	3rd Qu.:13.89	3rd Qu.:3.618	3rd Qu.:1.630
Max. :1.534	Max. :17.38	Max. :4.490	Max. :3.500
Si	K	Ca	Ba
Min. :69.81	Min. :0.0000	Min. : 5.430	Min. :0.0000
1st Qu.:72.19	1st Qu.:0.1100	1st Qu.: 8.325	1st Qu.:0.0000
Median :72.78	Median :0.5500	Median : 8.675	Median :0.0000
Mean :72.61	Mean :0.4932	Mean : 9.047	Mean :0.1895
3rd Qu.:73.07	3rd Qu.:0.6000	3rd Qu.: 9.418	3rd Qu.:0.0000
Max. :75.41	Max. :6.2100	Max. :16.190	Max. :3.1500
Fe	Type	hardness	density
Min. :0.00000	Min. :1.000	Min. :1.000	Min. :1.991
1st Qu.:0.00000	1st Qu.:1.000	1st Qu.:2.000	1st Qu.:2.358
Median :0.00000	Median :2.000	Median :4.000	Median :2.487
Mean :0.05478	Mean :2.412	Mean :3.758	Mean :2.499
3rd Qu.:0.09750	3rd Qu.:4.000	3rd Qu.:5.000	3rd Qu.:2.617
Max. :0.51000	Max. :5.000	Max. :7.000	Max. :3.028
thermal_exp			
Min. : 5.197			
1st Qu.: 7.971			
Median : 9.033			
Mean : 9.018			
3rd Qu.:10.046			
Max. :12.172			

RI	Si	Na	density	thermal_exp	Ca
0.002089285	0.011297771	0.063155740	0.077034630	0.165150703	0.165275035
Al	hardness	Mg	Type	K	Fe
0.355153852	0.507853168	0.571899760	0.592820556	1.420877170	1.759191850
Ba					
2.735458238					

color transparency	
[1,]	124 13
[2,]	27 41
[3,]	31 128

color transparency	
[1,]	68.13 7.14
[2,]	14.84 22.53
[3,]	17.03 70.33

Por ahora se decide no eliminar ninguna variable, ya que ninguna de ellas presenta un comportamiento constante o casi constante. Se considera que todas pueden aportar información valiosa al análisis.

Variable de significado desconocido

Para la variable thermal_exp, no se conoce su significado concreto, por lo que se decide su eliminación.

Análisis descriptivo


Valores inconsistentes o anómalos

A continuación se analiza si alguna de las variables presenta valores inconsistentes, es decir, valores que no son posibles dentro del rango de definición de la variable. Conviene plantear si estos datos se deben a un error

(en cuyo caso se sustituyen por NA), o si son valores posibles pero extremos que podrían aportar información interesante sobre el comportamiento de la variable.

Por un lado, el estudio de los valores anómalos de las variables numéricas parte de la representación de cada una de ellas en un diagrama de caja y bigotes, al adoptar el análisis una perspectiva univariante. Como se puede deducir a partir de los resultados del apartado anterior, observando los valores medios para cada variable, los datos se encuentran en rangos diferentes.


Es por ello que, con el objetivo de representar todos los boxplots juntos y analizar la presencia de valores atípicos en términos relativos evitando distorsiones en el gráfico, estandarizamos previamente las variables haciendo uso de la función “scale”.



De esta forma, a primera vista identificamos valores atípicos en la mayoría de las variables, siguiendo estas distribuciones asimétricas.

Destacan valores extremos en las variables K y Ba, que corresponden al contenido en potasio y bario que presentan los cristales. Para analizar mejor estas propiedades, las representamos individualmente en gráficos de caja y bigotes e histogramas.

Histogram of data\$K



```

0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09 0.1 0.11 0.12 0.13 0.14 0.15 0.16
28 1 1 2 1 4 1 3 2 1 4 2 2 2 1 1
0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
1 1 3 3 1 1 2 1 1 1 1 1 1 2 1 3
0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59 0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
3 1 4 5 9 11 10 6 11 7 5 5 3 2 3 3
0.69 0.7 0.72 0.76 0.81 0.97 1.41 1.46 1.68 1.76 2.7 6.21
1 1 1 2 1 1 1 1 1 1 1 2

```

A partir del histograma podemos deducir que la proporción relativa de potasio en los cristales se mueve entre valores de 0 y 3, por lo que interpretamos los dos valores extremos 6.21 como errores (valores inconsistentes) y los reemplazamos por valores faltantes (NA).

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
0.0000	0.1100	0.5500	0.4297	0.6000	2.7000	2


```

0 0.02 0.03 0.04 0.05 0.06 0.07 0.08 0.09 0.1 0.11 0.12 0.13 0.14 0.15 0.16
28 1 1 2 1 4 1 3 2 1 4 2 2 2 1 1
0.17 0.18 0.19 0.23 0.31 0.32 0.33 0.35 0.37 0.38 0.39 0.44 0.45 0.47 0.49 0.51
1 1 3 3 1 1 2 1 1 1 1 1 1 2 1 3
0.52 0.53 0.54 0.55 0.56 0.57 0.58 0.59 0.6 0.61 0.62 0.64 0.65 0.66 0.67 0.68
3 1 4 5 9 11 10 6 11 7 5 5 3 2 3 3
0.69 0.7 0.72 0.76 0.81 0.97 1.41 1.46 1.68 1.76 2.7
1 1 1 2 1 1 1 1 1 1 1

```


Respecto al contenido en bario, al hacer la representación podemos deducir que se trata de un elemento


presente en los cristales en proporción muy dispar, quedando reflejado en la asimetría de la distribución. No interpretamos los valores como inconsistentes, por lo que mantenemos los valores anómalos en la base de datos, como reflejo del comportamiento real de la variable.



0	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09	0.1	0.11	0.12	0.13	0.14	0.15	0.16
28	1	1	2	1	4	1	3	2	1	4	2	2	2	1	1
0.17	0.18	0.19	0.23	0.31	0.32	0.33	0.35	0.37	0.38	0.39	0.44	0.45	0.47	0.49	0.51
1	1	3	3	1	1	2	1	1	1	1	1	1	2	1	3
0.52	0.53	0.54	0.55	0.56	0.57	0.58	0.59	0.6	0.61	0.62	0.64	0.65	0.66	0.67	0.68
3	1	4	5	9	11	10	6	11	7	5	5	3	2	3	3
0.69	0.7	0.72	0.76	0.81	0.97	1.41	1.46	1.68	1.76	2.7					
1	1	1	2	1	1	1	1	1	1	1					

Para el análisis de las variables categóricas, optamos por un resumen descriptivo representando las frecuencias de cada valor en un gráfico de barras, al tener pocas categorías diferentes.





No identificamos ningún valor inconsistente en los datos de color y transparencia de los cristales.

Valores faltantes

Transformación y recodificación de variables

Antes de avanzar, es necesario revisar si nuestras variables necesitan algún ajuste para que el análisis sea más fluido. En este apartado evaluaremos si la composición química y las características cualitativas del cristal, como el color, están en el formato óptimo. Veremos si es mejor reagrupar algunas categorías pequeñas o crear variables binarias que nos ayuden a simplificar la información. No buscamos cambiar los datos por cambiar, sino adaptarlos para que la base de datos esté bien alineada con el foco de nuestro estudio y responda mejor cuando empecemos a clasificar los tipos de cristales.

Transformar variables categóricas a variables 0-1.

Comenzaremos con la transformación de las variables categóricas para asegurar su compatibilidad con los modelos analíticos. Convertiremos las categorías de los tipos de colores o transparencia de los cristales en variables numéricas de 0 y 1. Esta recodificación es fundamental porque transformare la información cualitativa en datos cuantitativos que los algoritmos de clasificación como PCA puedan procesar eficientemente, permitiéndonos integrar todas las propiedades del cristal en un único conjunto de datos numérico.

	colorCL	colorOT	colorWH	transparencyTL	transparencyTP
id1	0	0	1	1	0
id2	0	0	1	0	1
id3	1	0	0	0	1
id4	1	0	0	1	0

id5	1	0	0	1	0
id6	1	0	0	0	1

Esta matriz la añadiremos como columnas nuevas a la base de datos para cada tipo de color y nivel de transparencia. En cada fila (cristal), se marcará con un ‘1’ la columna que corresponda a su característica real, y con un ‘0’ aquellas que no apliquen, permitiendo así que el modelo identifique sus propiedades cualitativas mediante valores numéricos.

	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	Type	hardness	density
id1	1.51593	13.25	3.45	1.43	73.17	0.61	7.86	0	0.00	2	4	2.801783
id2	1.51711	12.89	3.62	1.57	72.96	0.61	8.11	0	0.00	2	4	2.600649
id3	1.52177	13.20	3.68	1.15	72.75	0.54	8.52	0	0.00	2	5	2.152241
id4	1.51818	13.72	0.00	0.56	74.45	0.00	10.99	0	0.00	2	7	2.289597
id5	1.51829	13.24	3.90	1.41	72.33	0.55	8.31	0	0.10	2	6	2.443725
id6	1.51665	13.14	3.45	1.76	72.48	0.60	8.38	0	0.17	3	4	2.504865

	colorCL	colorOT	colorWH	transparencyTL	transparencyTP
id1	0	0	1	1	0
id2	0	0	1	0	1
id3	1	0	0	0	1
id4	1	0	0	1	0
id5	1	0	0	1	0
id6	1	0	0	0	1

Tras esta transformación, disponemos de una base de datos completamente numérica y mejor estructurada, garantizando la compatibilidad necesaria para aplicar con precisión técnicas avanzadas como PCA y clustering en los próximos análisis.


Reagrupar categorías poco frecuentes

Tras analizar la distribución de la variable color, se ha observado que la mayoría de las observaciones se concentran en dos categorías principales, existiendo una tercera clase denominada ‘Others’ que agrupa eficientemente las tonalidades minoritarias. Dado que esta estructura ya garantiza que ninguna categoría tenga una frecuencia insignificante que pudiera desestabilizar los modelos matemáticos posteriores, se ha decidido mantener la variable tal como está, procediendo directamente a su transformación en variables dummy sin necesidad de realizar reagrupaciones adicionales.


Transformaciones para conseguir normalidad o simetría (Autoescalado)

Con la base de datos ya convertida a un formato puramente numérico, el siguiente paso fundamental es la normalización (o estandarización) de las variables. Dado que características como el índice de refracción (RI) y el contenido de sodio (Na) tienen escalas y unidades de medida muy distintas, es crucial ajustar todas las variables para que tengan una media de cero y una desviación estándar de uno. Esto evita que las variables con valores numéricos más altos dominen artificialmente los cálculos de distancia, asegurando que técnicas como el PCA y el clustering ponderen correctamente la influencia de todas las propiedades del cristal, independientemente de su magnitud original.

Para determinar el método de normalización más adecuado, realizaremos una comparación visual entre la distribución original de las variables numéricas y su comportamiento tras aplicar una transformación logarítmica. Mediante gráficos de densidad, evaluaremos qué enfoque corrige mejor la asimetría de los datos, asegurando que la estructura resultante sea óptima para los análisis multivariantes posteriores.



Densidad Na (Transformada log2)



```

      RI      Na      Mg      Al      Si
-1.691959e-14  6.970300e-16 -1.404173e-16 -1.319057e-16 -8.187275e-15
      K      Ca      Ba      Fe
      NA  4.716160e-17 -9.378945e-18 -2.104544e-17

```

```

RI Na Mg Al Si  K Ca Ba Fe
1  1  1  1  1 NA  1  1  1

```

La necesidad de estandarizar las variables mediante un Z-score (ajustando media a cero y desviación estándar a uno) radica en la disparidad de escalas y unidades de medida entre los componentes químicos del cristal. Este paso es crucial para evitar que variables con valores absolutos elevados dominen el análisis, garantizando que el PCA y el Clustering detecten patrones basados en la verdadera relevancia estadística de cada característica, no solo en su magnitud.

character(0)

[1] "Medias (deben ser casi 0):"

```

      RI      Na      Mg      Al      Si
      0      0      0      0      0
      K      Ca      Ba      Fe      Type
      NA      0      0      0      0
hardness    density    colorCL    colorOT    colorWH
      0      0      0      0      0
transparencyTL transparencyTP
      0      0

```

[1] "Desviaciones típicas (deben ser 1):"

```

      RI      Na      Mg      Al      Si

```

1	1	1	1	1
K	Ca	Ba	Fe	Type
NA	1	1	1	1
hardness	density	colorCL	colorOT	colorWH
1	1	1	1	1
transparencyTL	transparencyTP			
1	1			

Tras finalizar la estandarización de las variables, se ha verificado correctamente centrando y escalando nuestras variables numéricas obteniendo una media de cero y una desviación de uno. Este resultado confirma que la base de datos está perfectamente equilibrada y optimizada para las técnicas de PCA y clustering.

Análisis de Componentes Principales [5 páginas máximo]


El PCA se ha aplicado para reducir la dimensionalidad de la base de datos e identificar las relaciones entre las variables físico-químicas de los cristales.

Tratamiento de los datos

Se utilizaron todas las variables numéricas exceptuando el identificador `id` y `thermal_exp`. Los valores inconsistentes en la variable Potasio (K) fueron sustituidos por NA, permitiendo el uso del algoritmo NIPALS. Las variables categóricas (color y transparencia) ya fueron transformadas como variables dummy (0-1).

Y ya se aplicó el centrado y escalado estándar a todas las variables para evitar que aquellas con magnitudes más grandes dominen el análisis.

Selección del número de componentes principales



Como podemos observar en el scree plot nos recomienda coger un total de 7 componentes principales, para comprobar que es una correcta selección de componentes, aplicaremos el criterio de Kaisel


comp	eigenVal	percVar	cumPercVar
1	3.836032	22.5649	22.5649
2	2.473282	14.5487	37.1136
3	1.826782	10.7458	47.8594
4	1.660896	9.7700	57.6294
5	1.397556	8.2209	65.8503
6	1.230758	7.2398	73.0900
7	1.001531	5.8914	78.9814

El criterio de Kaiser elige las componentes donde varianza propia es superior a 1. Esto sugiere retener siete componentes. Estas siete componentes explican el 78.98% de la varianza acumulada. Aunque las primeras dos componentes capturan el 37.11% de la varianza, las componentes adicionales revelan patrones químicos importantes que no deben ignorarse en la caracterización de cristales, permitiendo capturar tanto los elementos mayoritarios como los minoritarios, con un porcentaje muy proximo al 80%.

Interpretación de resultados

Componentes 1 y 2 (37.11% de varianza)

Las dos primeras componentes separan claramente los cristales según sus propiedades de refracción y composi-




ción química principal.

La primera componente actúa como eje de densidad y refracción (RI y Ca dominantes). La segunda diferencia químicamente mediante Mg vs Al y Ba. Se observan cristales segregados (id107, id108) con perfiles químicos singulares.


Componentes 3 y 4 (20.52% de varianza)

Estas componentes capturan la variabilidad de unos elementos minoritarios.




La componente 3 está condicionada por variaciones en K (id185). La componente 4 captura variabilidad del Fe (id202). Estas dimensiones revelan muestras atípicas no detectadas en los primeros planos.

Componentes 5 y 6 (15.46% de varianza)




La componente 5 refleja variaciones en Na y Si. La componente 6 captura principalmente variabilidad en Type y hardness. Estas componentes son importantes para distinguir cristales con propiedades secundarias distintas.

Componente 7 (5.89% de varianza)




Biplot: Contribución de variables




Validación del modelo

Comenzaremos con la detección de anomalos moderados utilizando scr

Moderate outliers



Moderate outliers




```
[1] "Cristales moderados detectados:"
```

```
      id132      id150      id145      id35      id146      id54      id33      id76  
25.76386 25.02034 22.82842 16.00370 14.78040 12.99839 12.44513 11.56901
```

Vemos que falla id108, id107, id 112

There are no severe outliers in the data or they were not computed.

There are 3 moderate outliers in the data provided.



\$contribT2

NULL

\$contribRSS

	RI	Na	Mg	Al	Si	K
id132	4.3676678	5.173579	-1.6589560	-25.49833504	2.8619213	33.699920
id150	3.9982708	3.919398	-2.4833445	-10.38508130	0.6905711	5.840585
id145	0.4544178	-2.218341	0.3870336	-0.09579615	-0.1475496	-1.946937

	Ca	Ba	Fe	Type	hardness	density
id132	0.4425252	-1.635076	-3.9079159	2.916533123	2.1300846	2.015695
id150	-1.0681191	44.132882	-0.5605366	0.009376376	-0.5013354	-5.230634
id145	-1.1490192	61.752165	-4.8724787	-4.450276072	-0.5224039	-12.565623

	colorCL	colorOT	colorWH	transparencyTL	transparencyTP
id132	-0.0004059595	6.117129	-5.352771	-0.08479674	2.1366874
id150	1.4192387696	-12.499868	3.483039	3.56818448	-0.2095354
id145	0.5924012044	-4.597738	1.152227	2.56835155	-0.5272400

Reglas de asociación [OPCIONAL. 2 páginas máximo]

Análisis Factorial de Correspondencias [OPCIONAL. 2 páginas máximo]