

Estudio sobre los Cristales

Mario Álvarez Martínez, Jorge Aranda Honrubia, Pablo de Puelles Carceles, Julia Ruiz Picó, Cristina T

2026-06-07

Descripción de la BBDD

Variable	Tipo	Descripción
RI	numerical	Índice de refracción
Na	numerical	Proporción relativa de sodio
Mg	numerical	Proporción relativa de magnesio
Al	numerical	Proporción relativa de aluminio
Si	numerical	Proporción relativa de silicio
K	numerical	Proporción relativa de potasio
Ca	numerical	Proporción relativa de calcio
Ba	numerical	Proporción relativa de bario
Fe	numerical	Proporción relativa de hierro
type	categorical	Tipo de cristal según su uso (1: ventanas edificios vidrio flotado, 2: ventanas edificios sin
hardness	numerical	Dureza en escala ordinal Mohs, con mínimo 1 y máximo 7
color	categorical	Color del cristal (CL: transparente, WH: blanco, OT: otros colores)
transparency	categorical	Nivel de transparencia (TP: transparente, TL: translúcido, OP: opaco)
density	numerical	Densidad

Nos encontramos ante una base de datos que registra información sobre distintos cristales. La base original procede del conjunto de datos Glass del paquete mlbench de R.

En este caso quedan registradas un total de 14 variables para 171 muestras de cristales.

Las variables constantes fueron estudiadas, se trataron los valores extremos y se conservan las variables categóricas con su notación original.

Además, se eliminaron 11 muestras, al tratarse de valores anómalos severos detectados durante el Análisis de Componentes Principales. Para los futuros análisis prescindimos de las transformaciones logarítmicas aplicadas a las variables K y Ba, ya que se comprobó que no tenían el efecto deseado sobre las distribuciones.

Análisis Clustering


Descripción de los datos utilizados

El objetivo del análisis clustering aplicado a esta base de datos es encontrar grupos de cristales que tengan propiedades químicas similares. Para ello, se incluyen en el modelo las 8 variables numéricas que recogen la proporción relativa de 8 elementos químicos. Además, se emplearán las variables categóricas type, hardness, color y transparency como auxiliares, tratando de determinar si existe una relación entre los clusters formados y las categorías predefinidas de estas.

Es necesario aplicar un centrado y escalado de los datos, pues las magnitudes difieren significativamente de unos elementos químicos a otros. Además, se imputan los dos valores faltantes de la variable potasio K.

Elección de la medida de distancia y tendencia de agrupamiento

Estudiamos la tendencia de agrupamiento que presentan las observaciones a partir de su representación en un mapa de calor, tanto para la distancia euclídea como para la de Manhattan.



Dado que no existen diferencias significativas en la identificación de clústeres para cada distancia, optamos por emplear la euclídea para el resto del análisis, pues nos ofrece más herramientas al ser compatible con diversos métodos de clustering.

Además, se considera que, tras haber eliminado los valores anómalos de nuestra base de datos, se puede prescindir de la robustez que aportaría la distancia de Manhattan, obteniéndose con ambas resultados similares.

En principio, podemos identificar la presencia de un clúster mayor, y varios de menor tamaño pero mejor definidos. Respaldamos estos indicios de agrupamiento calculando el Índice de Hopkins.

Obtenemos valores próximos a 1, concretamente entre 0.99 y 1, para todos los valores de m y semillas aleatorias empleadas, por lo que se confirma la tendencia de agrupamiento.

Determinación del número de clústeres

Modelos jerárquicos

Para determinar el número de clústers de nuestro modelo, se aplicarán en primer lugar modelos jerárquicos (método de Ward, de la media, del centroide, del vecino más próximo y del vecino más lejano).


Se obtienen dos gráficos para cada uno, lo que permite comparar el coeficiente de Silhouette (que queremos que sea máximo, pues cuantifica cómo de buena es la asignación) y la variabilidad intra-clúster (que queremos minimizar) para cada número de clústers.

Recogemos la cantidad de clústers que consideramos óptima según cada método en la siguiente tabla:

	Método	Clústers	Silhouette	WSS
1	ward	5	0.3146	605.74
2	average	6	0.4076	750.88
3	centroid	5	0.3780	1113.08
4	single	5	0.4213	1130.74
5	complete	6	0.3805	705.55

Además, representamos cada dendograma, pudiendo concluir que, a excepción del método de Ward, el número de clústers propuesto no es adecuado para nuestro análisis. Para los cuatro últimos métodos, las observaciones quedan concentradas en un clúster principal que contiene la mayoría de muestras de cristales y varios clústeres más pequeños que presentan tan solo 1 o 2 observaciones.

Representamos los gráficos para el método de Ward, donde se observa que el valor óptimo de Silhouette, a excepción de en 2 clústers, queda entre 5 y 10 clústers, ya que el coeficiente de Silhouette se mantiene más o menos constante y la variabilidad intra-clúster ha disminuido bastante, a partir del codo de la gráfica.



Para decantarnos por un número de clústers aplicamos varios criterios haciendo uso de la librería NbClust.


Concluimos, al tratarse del número de clústers más votado con diferencia, que el óptimo para el método de Ward son 6 clústers. En el dendograma se observan 4 clústers equilibrados en cuanto al número de observaciones, uno un poco mayor, y el más pequeño con tan solo 5 muestras de cristales.

```

clustWard
  1  2  3  4  5  6
56 23 31 37 19  5



```

Cluster Dendrogram



Métodos de partición


Aplicamos el algoritmo k-medias y el k-medoides para determinar el número óptimo de clusters y poder compararlo con el resultado obtenido a partir de los métodos jerárquicos.



El método de k-medias indica 6 clústers como el número óptimo, en el que, nuevamente, se identifica un clúster más pequeño con 5 muestras de cristales.


1 2 3 4 5 6
29 5 72 14 29 22

Para k-medoides, la cantidad de clústers más apropiada está entre 5 y 6, tal como se ve representado en el gráfico. El criterio WSS ubica el codo en 5 clústers, por lo que nos decantamos por esta cantidad al no haber diferencias notables en los coeficientes de Silhouette.



Comparación de métodos de clustering

Para tomar la decisión final respecto al número de clústers y el método empleado, comparamos los resultados hasta el momento (Ward, k-means, k-medoides). Para ello, se analizan los coeficientes de Silhouette por clúster y las muestras mal clasificadas.



En primer lugar, descartamos emplear el método de Ward. Su coeficiente de Silhouette global es el menor y la mayoría de sus clústers presentan bastantes observaciones que no pertenecen al cluster donde fueron

asignadas. Además, tres de ellos presentan valores de Silhouette reducidos (menores a 0.10).

Respecto k-medias, tiene el valor global más alto (0.37) y dos de sus clústers también tienen un coeficiente de Silhouette muy positivo, sin muestras mal clasificadas. El peor clúster (0.10), coincide con el que tan solo contiene 5 individuos.

Por último, k-medoides tiene valores más estables del coeficiente de Silhouette para cada clúster, siendo el global 0.32. No presenta un número excesivo de observaciones mal clasificadas.

Para tomar una decisión, aplicamos medidas internas y de estabilidad para cada opción planteada,


	Score	Method	Clusters
APN	0.10401451	kmeans	5
AD	2.15027608	kmeans	6
ADM	0.46408248	kmeans	6
FOM	0.78122580	kmeans	6
Connectivity	43.37380952	hierarchical	5
Dunn	0.06969365	pam	6
Silhouette	0.36752951	kmeans	6

La mayoría de medidas de estabilidad sugieren los 6 clústers de k-medias como la opción óptima, lo que también ocurre para Silhouette. Nos decantamos por este método.



Interpretación de los resultados del clustering


Caracterización de los clústeres obtenidos

En primer lugar, vamos a realizar un análisis de PCA completo para ver cuáles de las variables utilizadas en el clustering han contribuido más a la determinación de los clusters obtenidos mediante k-medias. Se emplean los datos ya validados en el procedimiento de PCA de la entrega anterior (centrados, escalados y con la eliminación de anómalos severos).




Basándonos en el criterio de contención de como mínimo el 80% de la variabilidad original, tomamos 4 componentes principales, lo que además facilitará la representación gráfica dos a dos.





El clúster 1 se caracteriza por su alto contenido en calcio y magnesio, y sus bajas proporciones de potasio, bario y aluminio. El clúster 2 presenta una alta proporción de bario y aluminio y bajo contenido en calcio. El clúster 3, muy concentrado, agrupa muestras sin proporciones extremas de ningún elemento. En el clúster 4 se incluyen cristales con alto contenido en calcio y silicio. El clúster 5 destaca por la elevada proporción de hierro. Y el clúster 6, también compacto, recoge observaciones ricas en Na, Ba y Al.

Perfil medio de los clusters



Esta representación respalda la interpretación de los clústeres propuesta a partir del PCA.

Relación de los clústeres con otras variables

Por último, se estudia la relación entre los clústeres que hemos formado y las variables type, color, hardness y transparency:

	1	2	3	4	5	6
1	0.55172414	0.00000000	0.44444444	0.00000000	0.41379310	0.00000000
2	0.10344828	0.00000000	0.44444444	0.28571429	0.48275862	0.00000000
3	0.13793103	0.00000000	0.09722222	0.00000000	0.06896552	0.00000000
4	0.13793103	0.40000000	0.00000000	0.71428571	0.03448276	0.09090909
5	0.06896552	0.60000000	0.01388889	0.00000000	0.00000000	0.90909091

	1	2	3	4	5	6
CL	0.65517241	0.40000000	0.77777778	0.35714286	0.93103448	0.36363636
OT	0.13793103	0.40000000	0.00000000	0.42857143	0.00000000	0.59090909
WH	0.20689655	0.20000000	0.22222222	0.21428571	0.06896552	0.04545455

	1	2	3	4	5	6
OP	0.03448276	0.00000000	0.00000000	0.21428571	0.00000000	0.36363636
TL	0.10344828	0.20000000	0.26388889	0.21428571	0.24137931	0.22727273
TP	0.86206897	0.80000000	0.73611111	0.57142857	0.75862069	0.40909091

	1	2	3	4	5	6
1	0.17241379	0.00000000	0.16666667	0.07142857	0.17241379	0.09090909
2	0.06896552	0.00000000	0.16666667	0.14285714	0.13793103	0.27272727
3	0.13793103	0.40000000	0.19444444	0.21428571	0.10344828	0.27272727
4	0.27586207	0.40000000	0.12500000	0.28571429	0.17241379	0.04545455
5	0.13793103	0.00000000	0.18055556	0.07142857	0.06896552	0.00000000
6	0.10344828	0.00000000	0.09722222	0.14285714	0.13793103	0.00000000
7	0.10344828	0.20000000	0.06944444	0.07142857	0.20689655	0.31818182

La variable tipo es la que presenta una relación más clara con los clústeres formados:

El clúster 6 recoge casi exclusivamente cristales de tipo 5, empleados en faros y caracterizados por las proporciones químicas deducidas anteriormente. Por su parte, el clúster 4 concentra las muestras de tipo 4, cuyo uso va destinado a la fabricación de envases y artículos de mesa.

Y los cristales de tipo 1 y 2 (ventanas de edificios) se recogerían en los clusters 3 y 5 principalmente, lo que es lógico, pues las proporciones químicas de ambos clústers son similares, a excepción del hierro. Lo mismo sucede para la categoría CL de la variable color: destaca en estos dos clústers. Por tanto, podríamos vincular el color transparente a las ventanas de edificios.

La composición química del clúster 1 no puede asociarse a un uso ni un color concreto.

Respecto a las variables transparencia y dureza, no se perciben patrones claros, especialmente por el dominio que tiene la transparencia TP en la mayoría de clústers.

Sin embargo, podríamos relacionar los valores máximos de dureza (nivel 7) y opacidad (OP) presentes en el clúster 6 con el uso de los cristales de este clúster en faros, donde podrían requerirse estas características.

Modelos PLS [5 páginas máximo]

Descripción de los datos utilizados y objetivo

Optimización del modelo

Validación del modelo

Interpretación del modelo

Conclusiones

Análisis Discriminante [OPCIONAL. 2 páginas máximo]